

An In-Depth Exploration of Intraoperative Hypotension Prediction using Transformer Models



이름 양태규 지도교수 손경아 교수님

연구 배경

- 현재의 딥러닝 기술은 이미지 및 텍스트 분야에서 매우 뛰어난 성과를 보여줌.
- Signal data에 대한 딥러닝 연구는 여전히 어려움을 가지고 있으며 주로 데이터의 복잡성, 높은 차원, 제조사에 따른 센서 데이터의 차이 등에 기인함.
- 현실 세계의 문제를 Transformer 모델 기반 신호 처리 기술을 통해 보다 정확하게 예측해 보고자 함.

연구 진행 과정


Problem Definition:

- 수술실 생체 신호 데이터를 입력으로 하여 특정 시간 이후 저혈압 발생 여부(classification)와 혈압 수치(regression)를 예측함.

선행 연구:

- [1](S. Lee et al., 2021)에서는 혈압, 심전도, 광혈류 측정, 호기말 이산화탄소 등 시간 별로 나누어진 신호 데이터를 통해 5, 10, 15분 후 해당 환자에서 저혈압이 발생할지 여부를 1D CNN을 통해 예측하는 모델을 제시함.
- 혈압 신호(ART)는 침습적인 신호로 판단함. 침습적인 신호는, 해당 신호 데이터를 얻기 위해서 몸 속에 이물질을 투입하여 센서 데이터를 확보하는 것을 의미함

Dataset and Preprocessing:



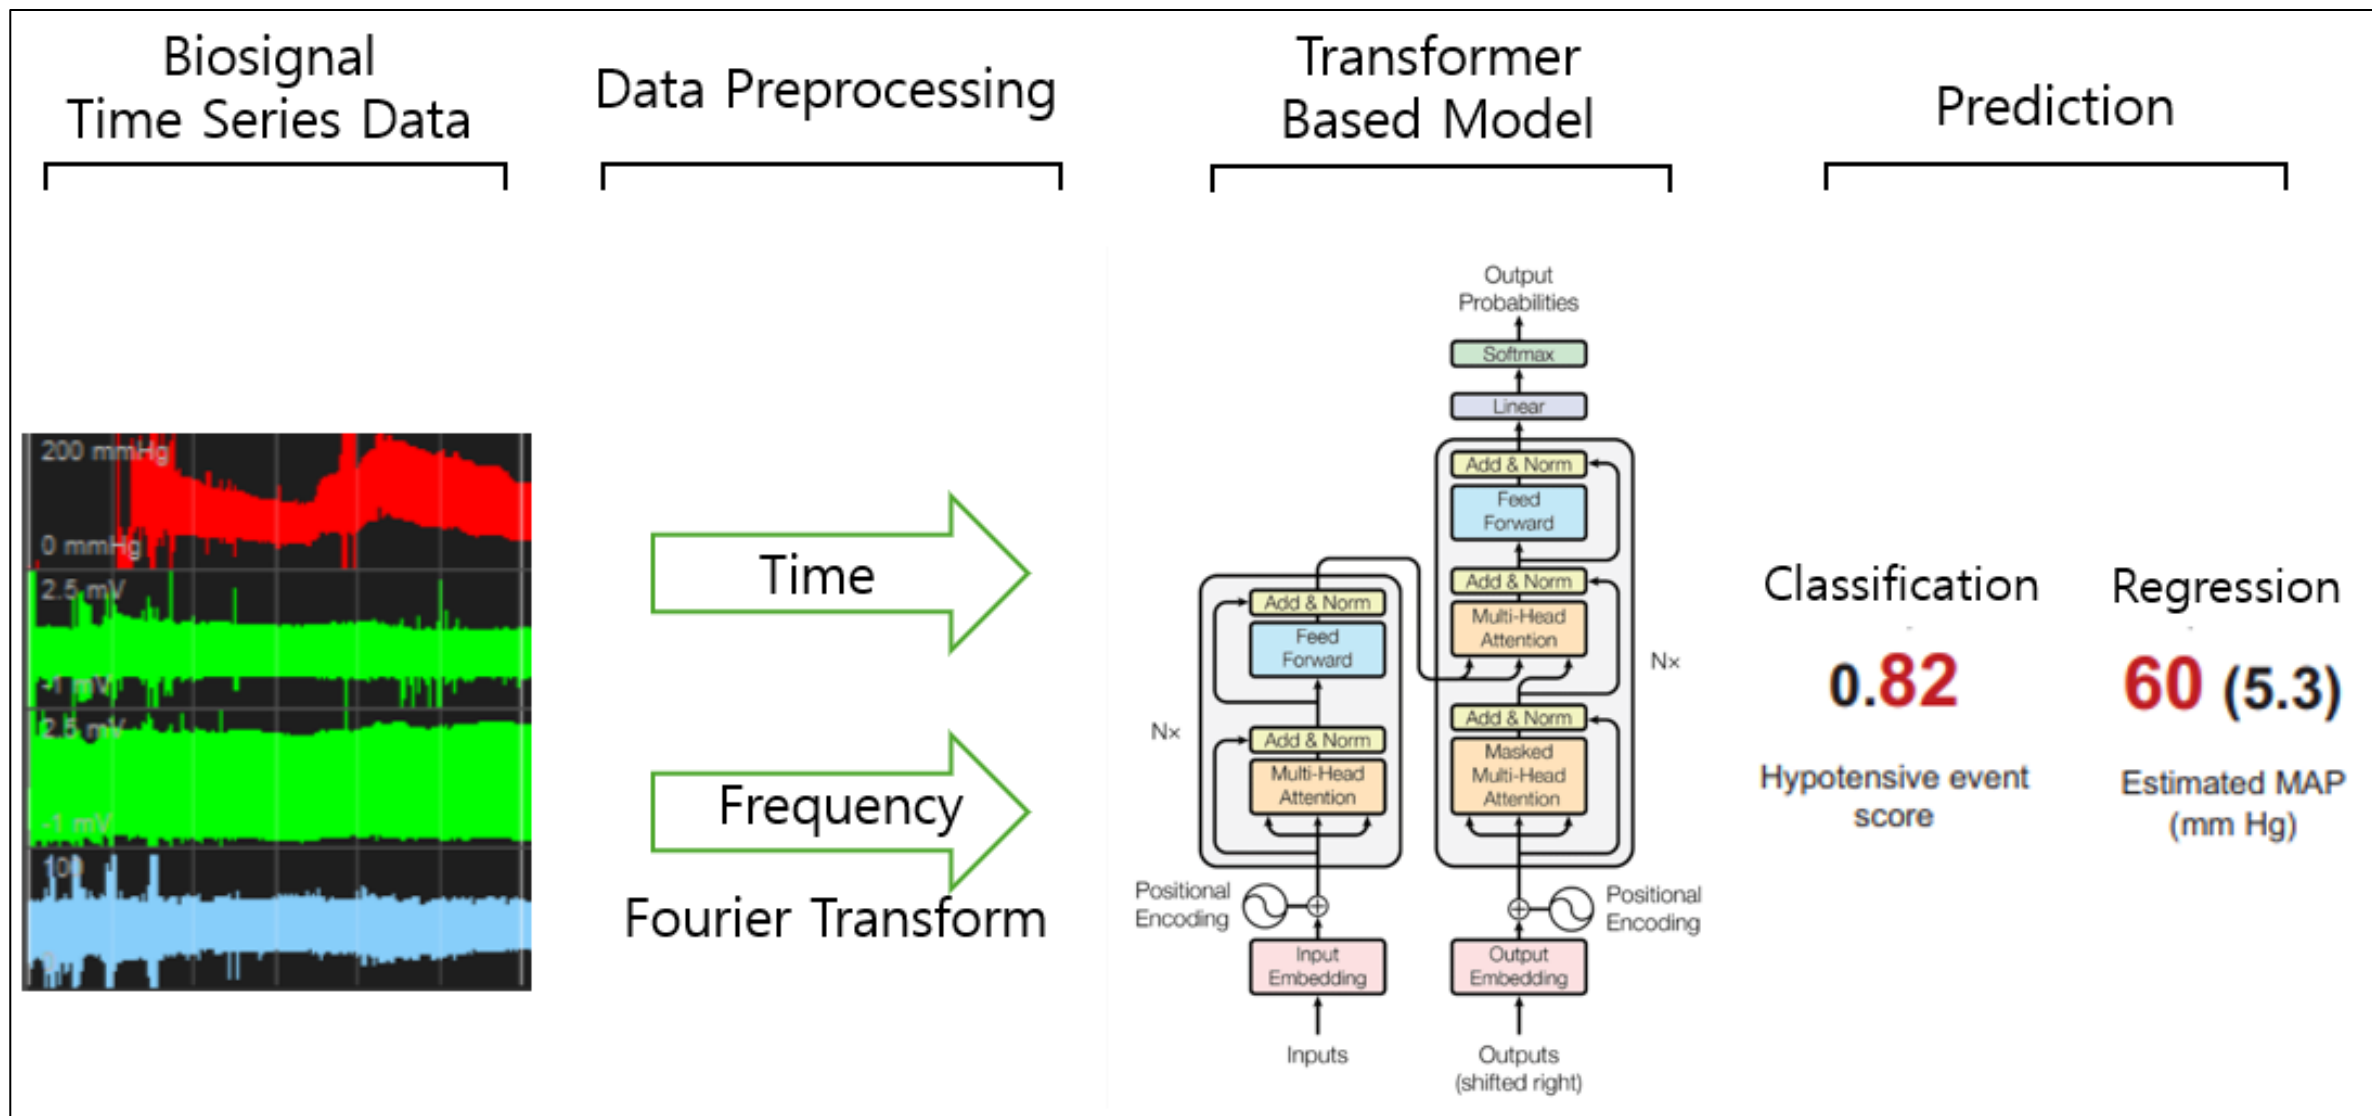
- Dataset으로는 VitalDB[2]에서 공개한 수술실 데이터를 raw data로 사용함.
- ART(혈압), EKG(심전도), PPG(광혈류 측정), CO2(호기말 이산화탄소)의 신호를 사용함.
- 혈압이 너무 낮거나 너무 높아 학습에 영향을 미치는 부분을 outlier로 제외하고 정규화를 수행함.
- 학습에 사용되는 환자 데이터 수는 3301명의 혈압 등의 신호임. train, validation, test로 각각 6:1:3으로 나누어 학습이 진행됨.
- Frequency domain에서 학습하기 위한 데이터는 위에서 전처리한 time domain의 데이터에 Fourier transform을 적용함.
- 학습 데이터를 30초 단위로 자르고, 1초당 100번의 신호를 지니고 있어, 학습에 사용되는 input data의 길이는 3000이 됨.

Model:

- Informer[2020]에서 제시한 ProbSparse라는 아이디어를 사용하여 Vanilla Transformer보다 향상된 성능으로 저혈압을 예측함. ProbSparse는 attention을 수행할 때, query-key 쌍에서 학습에 크게 영향을 미치는 지배적인 query-key 쌍을 찾아서 활용함.

- FEDformer[2022]에서는 시계열 데이터를 주기성과 추세성으로 분해하여 학습에 사용함. 크기가 다른 여러 개의 kernel을 통과한 값인 추세성을 얻고 나머진 주기성을 얻음.

연구 내용:



- VitalDB의 데이터를 이용하여 time과 frequency domain feature로 전처리함. Transformer와 그 발전된 모델들로 학습하여 분류와 회귀 문제를 예측함.

결과 및 분석

Time domain VS Frequency domain:

	Invasive/multi/300	Noninvasive/multi/300
Time	0.932	0.853
Frequency + Time	0.937	0.898

- Frequency domain을 같이 학습한 경우가 Time domain만 학습한 결과보다 평균적으로 더 우수한 성능을 보임.

기존 모델과의 성능 비교:

Model	Classification AUROC	Regression MSE
1d_cnn	0.932	7.1
1d_cnn + Freq	0.937	-
Vanilla Transformer	0.843	6.9
Informer	0.936	5.8
FEDformer	-	6.5

- Transformer 모델의 경우, classification 문제에서는 1D CNN 등 기존 baseline 모델보다 5분 뒤 저혈압 발생 유무에 대한 예측을 못하는 것으로 결과가 도출됨. 하지만 regression 문제에서는 약간 우수한 모습을 보임.
- Informer의 경우 classification과 regression 문제 모두 기존 baseline 모델보다 우수한 성능을 보임. Frequency domain에서도 학습한 모델과 분류 문제에서 유사한 성능을 나타냄. Attention을 수행할 때, 학습에 지배적인 영향을 끼치는 query만 선택하여 attention을 하는 것이 시계열 데이터를 분석하는 것에 있어 좋은 성능을 보인다고 할 수 있음.
- FEDformer의 경우, regression 문제에서는 1d_CNN과 vanilla transformer 보다 우수한 성능을 보임. 시계열 데이터를 추세성과 주기성으로 분해하여 학습하는 것이 도움이 된다고 볼 수 있음.

참고 문헌

[1]S. Lee et al., "Deep learning models for the prediction of intraoperative hypotension," British Journal of Anaesthesia, vol. 126, no. 4, pp. 808-817, Apr. 2021, doi: <https://doi.org/10.1016/j.bja.2020.12.035>.
[2]"VitalDB," vitaldb.net. <https://vitaldb.net/> (accessed Mar. 01, 2024).

